

MPM 多组学生物标志物知识图谱构建与查询系统

项目规格说明书 (Project Specification)

Hengxi Liu

2026 年 8 月

目录

1 摘要	5
2 项目背景	5
2.1 恶性胸膜间皮瘤 Malignant Pleural Mesothelioma (MPM)	5
2.2 多组学整合 Multi-omics Integration	7
3 知识图谱简介 Knowledge Graph Introduction	7
4 项目目标	8
5 项目流程总览	9
6 Phase 1: 确定项目方向	9
6.1 项目主体定义	9
6.2 目标疾病选择	10
6.3 技术路线	10
7 Phase 2: 需求分析	10
7.1 数据需求	10
7.2 功能性需求 Functional Requirements (FR)	11
7.3 非功能性需求 Non-functional requirements (NFR)	11

8 Phase 3: 知识图谱数据模型建立 Knowledge Graph Schema Design	12
8.1 实体图谱	12
8.2 关系图谱	12
9 Phase 4: 原始数据集建立	13
9.1 数据来源选择	13
9.2 数据集建立流程	13
9.3 数据集规模	13
10 Phase 5: 实体标准化和数据清洗	14
10.1 统一实体模式	14
10.2 基因数据标准化	15
10.3 蛋白质数据标准化	15
10.4 信号通路数据标准化	16
10.5 药物数据标准化	16
10.6 疾病数据标准化	17
10.7 文献证据数据标准化	17
10.8 数据情绪	18
10.9 Phase 5 最终输出	18
11 Phase 6: 关系图谱建立	18
11.1 Phase 6.1: 关系图谱设计	19
11.2 Phase 6.2: 关系提取	20
11.3 Phase 6.3: 关系映射和验证	21
11.3.1 Level 1: 精确匹配	21
11.3.2 Level 2: 规范标识符映射	22
11.3.3 Level 3: 同义词及别名映射	22
11.3.4 Level 4: 排除未解决的关系	22
11.4 Phase 6.3 映射结果	23
11.5 Phase 6 最终输出	23
12 Phase 7: Neo4j 知识图谱构建	24
12.1 Phase 7.1: Neo4j 环境配置	24
12.2 Phase 7.2: Node 构建	25

12.3 Phase 7.3: 规范化别名与约束设计	26
12.4 Phase 7.4: 关系数据导入	27
12.5 Phase 7.5: 知识图谱系统验证	27
13 Phase 8: 知识图谱查询系统开发	28
13.1 Phase 8.1: 数据库建立模块	29
13.2 Phase 8.2: 实体查找功能	29
13.3 Phase 8.3: 关系搜索功能	30
13.4 Phase 8.4: 多条路径查询功能	30
13.4.1 查询功能设计	31
13.4.2 路径结果格式	32
13.4.3 Graph Formatter	32
13.5 Phase 8.5: 文献查询功能	33
13.5.1 查询对象	33
13.5.2 返回信息	34
13.6 Phase 8.6: 药物-靶点-疾病闭环查询功能	34
13.6.1 查询目标	35
13.6.2 查询链路	35
13.6.3 返回信息	36
13.7 Phase 8.7: Query Result Formatter	36
13.7.1 Relationship Graph Formatter	36
13.7.2 Multi-hop Graph Formatter	37
13.8 Phase 8.8: FastAPI 后端开发	38
13.9 Phase 8.9: Streamlit 交互式查询仪表盘开发	38
13.9.1 Dashboard 整体设计	39
13.9.2 Module 1: Entity Search	39
13.9.3 Module 2: Relationship Exploration	40
13.9.4 Module 3: Multi-hop Path Query	41
13.9.5 Module 4: Supporting Literature Evidence	42
13.9.6 Module 5: Drug-Target-Disease Chain	42
14 Phase 9: AI 增强、系统测试与评估	43
14.1 Phase 9.1: 知识图谱嵌入	43

14.2 Phase 9.2: 语义搜索	44
14.3 Phase 9.3: 大语言模型系统整合	44
14.4 Phase 9.4: 系统测试	45
15 当前项目状态	45
15.1 数据层成果	46
15.2 知识图谱构建成果	47
15.3 查询系统成果	48
16 系统架构总结	48
16.1 Knowledge Graph Database Layer	48
16.2 Backend Service Layer	49
16.3 Frontend Layer	49
17 Phase 1–9 完整流程总结	50
18 未来扩展	50
19 总结	51

1 摘要

恶性胸膜间皮瘤 (Malignant Pleural Mesothelioma, MPM) 是一种高度侵袭性的恶性肿瘤，其发生发展涉及复杂的基因突变、蛋白表达异常、信号通路变化以及药物响应机制。

随着高通量测序技术和生物医学数据库的发展，大量 MPM 相关数据不断产生。然而，由于不同数据库之间存在数据结构差异、实体命名不统一以及信息分散等问题，研究人员难以直接整合这些多维度信息。

本项目旨在构建一个面向 MPM 研究的多组学生物标志物知识图谱 (Multi-omics Biomarker Knowledge Graph)，通过整合 Gene、Protein、Pathway、Drug、Disease 以及 Publication 等多类型生物医学实体，建立统一的数据表示和关系网络。

项目整体流程包括：

1. 项目定义与需求分析；
2. Knowledge Graph Schema 设计；
3. Raw Dataset 构建；
4. Entity Normalization 与 Data Cleaning；
5. Relationship Construction；
6. Neo4j Knowledge Graph 数据库构建；
7. Query System 开发；
8. AI Enhancement 与系统测试。

最终系统将提供基于知识图谱的实体查询、关系探索、多跳路径发现、文献证据追踪以及药物-靶点-疾病闭环分析功能，为 MPM 相关生物医学研究提供统一的信息查询平台。

2 项目背景

2.1 恶性胸膜间皮瘤 Malignant Pleural Mesothelioma (MPM)

恶性胸膜间皮瘤 (MPM) 是一种来源于胸膜间皮细胞的罕见但高度恶性的肿瘤。MPM 通常与长期石棉暴露相关，并具有以下特点：

- 潜伏期长；
- 早期症状不明显；
- 临床诊断困难；
- 生存率较低；
- 治疗选择有限。

近年来，随着分子生物学技术的发展，研究人员发现 MPM 的发生发展涉及多个分子层面的异常，包括：

- 基因突变（例如 BAP1、TP53 等）；
- 蛋白功能异常；
- 信号通路改变；
- 药物靶向机制；
- 疾病相关分子网络。

然而，目前这些信息通常分布于：

- NCBI Gene；
- UniProt；
- KEGG；
- DrugBank；
- Disease Ontology；
- PubMed。

不同数据库之间的数据格式和实体标识存在差异，因此需要一种统一的数据组织方法。

2.2 多组学整合 Multi-omics Integration

多组学 (Multi-omics) 通过整合多个生物学层面的数据, 从整体角度描述疾病机制。
本项目主要关注以下组学层面:

Omics Layer	Entity	Example
Genomics	Gene	TP53, BAP1
Proteomics	Protein	Tumor suppressor proteins
Pathway	Biological Pathway	KEGG pathway
Pharmacology	Drug	Pemetrexed
Disease	Disease Entity	MPM
Literature	Publication	PubMed Evidence

表 1: Multi-omics Entity Layers

通过整合不同层级的数据, 可以建立:

$$Gene \rightarrow Protein \rightarrow Pathway \rightarrow Disease$$

以及:

$$Drug \rightarrow Protein \rightarrow Disease$$

这样的生物医学知识网络。

3 知识图谱简介 Knowledge Graph Introduction

知识图谱 (Knowledge Graph) 是一种以实体 (Entity) 和关系 (Relationship) 为核心的数据表示方法。

相比传统关系数据库:

- 知识图谱更加适合表示复杂关系;
- 支持多跳路径查询;
- 能够表达实体之间的语义联系;
- 方便进行 Graph-based Analysis。

本项目采用 Neo4j 作为 Graph Database。

知识图谱基本结构：

Entity → Relationship → Entity

例如：

Gene → ENCODES → Protein

Drug → TARGETS → Protein

Publication → SUPPORTS → Gene

4 项目目标

本项目主要目标如下：

1. 建立面向 MPM 研究的多组学生物医学知识图谱；
2. 从多个公共数据库收集 MPM 相关数据；
3. 建立统一 Entity Schema；
4. 对 Raw Dataset 进行 Normalization 和 Cleaning；
5. 建立 Relationship Schema；
6. 从数据和文献中提取 Validated Relationships；
7. 使用 Neo4j 构建 Graph Database；
8. 开发 Knowledge Graph Query System；
9. 实现 Interactive Visualization；
10. 为未来 AI 增强查询提供基础。

5 项目流程总览

整个项目划分为九个主要阶段：

1. Phase 1: Project Definition
2. Phase 2: Requirement Analysis
3. Phase 3: Knowledge Graph Schema Design
4. Phase 4: Raw Dataset Construction
5. Phase 5: Entity Normalization and Data Cleaning
6. Phase 6: Relationship Construction
7. Phase 7: Neo4j Knowledge Graph Construction
8. Phase 8: Query System Development
9. Phase 9: AI Enhancement, Testing and Evaluation

6 Phase 1: 确定项目方向

Phase 1 主要负责确定项目研究方向、目标疾病以及整体技术路线。

6.1 项目主体定义

项目主题定义为：

MPM 多组学生物标志物知识图谱构建与查询系统

核心研究问题：

如何利用知识图谱技术整合 MPM 相关多组学数据，并建立支持生物医学知识查询的平台。


6.2 目标疾病选择

选择恶性胸膜间皮瘤作为目标疾病主要原因：

- 疾病相关研究数据丰富；
- 分子机制复杂；
- 存在大量潜在 Biomarker；
- 适合进行 Multi-omics Integration。

6.3 技术路线

项目技术路线确定如下：



7 Phase 2: 需求分析

Phase 2 负责分析系统需求，包括数据需求、功能需求以及非功能需求。

7.1 数据需求

系统需要支持以下 Entity：

Entity Type	Description
Gene	Genetic biomarkers
Protein	Protein products
Pathway	Biological pathways
Drug	Therapeutic compounds
Disease	Disease ontology
Publication	Literature evidence

表 2: Required Entity Types

7.2 功能性需求 Functional Requirements (FR)

系统需要支持：

1. Entity Search;
2. Relationship Exploration;
3. Multi-hop Query;
4. Publication Evidence Query;
5. Drug-Target-Disease Analysis;
6. Graph Visualization。

7.3 非功能性需求 Non-functional requirements (NFR)

系统需要满足：

- 可扩展性；
- 查询效率；
- 数据可追溯性；
- 数据标准化；
- 用户交互友好。

8 Phase 3: 知识图谱数据模型建立 Knowledge Graph Schema Design

Phase 3 负责设计 Knowledge Graph 的数据模型。

8.1 实体图谱

最终 Entity Schema 设计如下：

Entity	Identifier
Gene	Gene ID
Protein	UniProt ID
Pathway	Pathway ID
Drug	DrugBank ID
Disease	DOID
Publication	PMID

表 3: Entity Schema Design

8.2 关系图谱

Relationship 采用：

$$SourceEntity \rightarrow Relationship \rightarrow TargetEntity$$

作为统一表示方式。

主要关系包括：

- Gene ENCODES Protein;
- Protein PARTICIPATES_IN Pathway;
- Drug TARGETS Protein;
- Drug TREATS Disease;
- Gene ASSOCIATED_WITH Disease;
- Publication SUPPORTS Entity。

9 Phase 4: 原始数据集建立

Phase 4 负责从多个权威生物医学数据库中收集与 MPM 相关的原始数据 (Raw Dataset)。

由于不同类型的生物医学实体具有不同的数据特点，因此本项目针对不同 Entity 选择对应的专业数据库作为主要数据来源。

9.1 数据来源选择

本项目主要使用以下数据库：

Entity Type	Primary Database	Purpose
Gene	NCBI Gene	Gene identifier and annotation information
Protein	UniProt	Protein information and function annotation
Pathway	KEGG	Biological pathway information
Drug	DrugBank	Drug information and therapeutic targets
Disease	Disease Ontology	Disease ontology standardization
Publication	PubMed	Biomedical literature evidence

表 4: Phase 4 主要数据来源

9.2 数据集建立流程

Raw Dataset (原始数据集) 的构建流程如下：

1. 根据 MPM 相关研究确定候选 Entity 范围；
2. 从对应公共数据库中收集原始数据；
3. 保留数据库中的原始 Identifier；
4. 建立初始 Excel Dataset；
5. 为后续 Normalization 和 Cleaning 提供输入。

Phase 4 阶段重点关注数据完整性，而不进行复杂的数据清洗。

9.3 数据集规模

Phase 4 完成后建立以下 Raw Dataset：

其中 Publication Dataset 作为 Knowledge Graph 中的 Evidence Layer，用于支持不同 Biomedical Entity 之间 Relationship 的可信度。

Entity Type	Quantity
Gene	50
Protein	50
Pathway	50
Drug	20
Disease	1
Publication	100

表 5: Raw Dataset 规模

10 Phase 5: 实体标准化和数据清洗

Phase 5 的目标是将 Phase 4 产生的 Raw Dataset 转换为统一、标准化、可用于 Knowledge Graph Construction 的 Entity Dataset (实体数据集)。

由于不同数据库之间存在：

- Entity naming inconsistency;
- Different identifier systems;
- Missing information;
- Duplicate records;
- Synonym problems。

因此需要进行 Entity Normalization (实体标准化)。

10.1 统一实体模式

本项目为所有 Entity 建立统一 Schema。

每个 Entity 至少包含：

- Canonical Identifier;
- Standard Name;
- Description;
- Source Database;
- Additional Annotation Information。

其中 Canonical Identifier 作为 Knowledge Graph 中的唯一身份标识。

10.2 基因数据标准化

Gene Entity 主要来源于 NCBI Gene。

Normalization 过程包括：

- Standard Gene Symbol 统一；
- Gene ID 验证；
- Gene Description 补充；
- Synonym 整理；
- Duplicate Gene Removal。

最终 Gene Schema 包括：

Field	Description
Gene _I D	NCBI canonical identifier
Standard _{Name}	Official gene symbol
Description	Gene functional description
Synonyms	Alternative names
Source	NCBI Gene

表 6: Gene Entity Schema

Gene_ID 作为 Neo4j 中 Gene Node 的 Unique Identifier。

10.3 蛋白质数据标准化

Protein Entity 主要来源于 UniProt。

Normalization 重点包括：

- UniProt accession 验证；
- Protein name 统一；
- Gene-protein mapping；
- Protein function 补充；
- Protein length 检查。

Protein Schema 包括：

Field	Description
UniProt _{ID}	Protein canonical identifier
Standard _{Name}	Protein name
Gene _{Symbol}	Related gene
Function	Functional annotation
Length	Amino acid length

表 7: Protein Entity Schema

10.4 信号通路数据标准化

Pathway Entity 主要来源于 KEGG，并使用 Reactome 作为辅助。

Normalization 包括：

- Pathway ID 统一；
- Pathway name 标准化；
- Related Gene mapping；
- Related Protein mapping。

Pathway_ID 作为唯一 Identifier。

10.5 药物数据标准化

Drug Entity 主要来源于 DrugBank。

Normalization 内容包括：

- DrugBank ID 验证；
- Drug Name 统一；
- Drug mechanism 补充；
- Drug target 整理；
- Clinical status 记录。

DrugBank_ID 作为 Drug Node 唯一 Identifier。

10.6 疾病数据标准化

Disease Entity 使用 Disease Ontology 进行标准化。

本项目核心疾病实体：

Malignant Pleural Mesothelioma

对应：

DOID:7474

作为 Disease Node 的 Canonical Identifier。

10.7 文献证据数据标准化

Publication Entity 主要来源于 PubMed。

PMID 作为唯一 Identifier。

标准字段包括：

- PMID;
- Title;
- Journal;
- Publication Year;
- DOI;
- Authors;
- Evidence Level;
- Main Finding。

Publication 不仅作为普通 Entity,同时作为 Knowledge Graph 中的 Evidence Source。

10.8 数据情绪

Phase 5 同时执行 Data Cleaning。

主要步骤包括：

1. Remove duplicate records;
2. Check missing identifier;
3. Verify identifier format;
4. Normalize naming convention;
5. Validate Entity mapping。

10.9 Phase 5 最终输出

Phase 5 最终输出：

- Cleaned Gene Dataset;
- Cleaned Protein Dataset;
- Cleaned Pathway Dataset;
- Cleaned Drug Dataset;
- Cleaned Disease Dataset;
- Cleaned Publication Dataset。

这些 Normalized Dataset 将作为 Phase 6 Relationship Construction 的基础。

11 Phase 6: 关系图谱建立

Phase 6 负责构建 MPM 多组学生物标志物知识图谱中的 Entity Relationship。

在 Phase 5 中，所有 Entity 已经完成 Normalization 和 Data Cleaning，并形成统一格式的 Normalized Dataset。因此 Phase 6 的主要目标是：

- 根据 Knowledge Graph Schema 定义 Entity 之间允许存在的 Relationship 类型；

- 从 Normalized Dataset 以及 Publication Evidence 中提取 Relationship Instance;
- 对不同来源的数据进行 Entity Mapping;
- 对 Relationship 进行 Validation;
- 生成最终用于 Neo4j Knowledge Graph Construction 的 Relationship Dataset。

Phase 6 不会直接将原始数据中的所有关联关系导入 Knowledge Graph, 而是采用:

Schema Definition → Relationship Extraction → Mapping → Validation

的标准 Knowledge Graph Construction 流程。

11.1 Phase 6.1: 关系图谱设计

Phase 6.1 首先定义 Knowledge Graph 中允许存在的 Relationship Schema。

Relationship Schema 用于描述:

- Relationship Type;
- Source Entity Type;
- Target Entity Type;
- Relationship Direction。

Relationship Schema 本身只定义关系结构, 而不包含具体 Entity Instance。

本项目最终设计的主要 Relationship 如下:

其中:

- Gene → Protein 表示基因编码蛋白质;
- Drug → Protein 表示药物作用靶点;
- Drug → Disease 表示药物治疗疾病;
- Publication → Entity 表示科研文献提供的 Evidence Support。

通过上述 Relationship Schema, 可以保证后续 Relationship Extraction 过程具有统一的数据结构。

Relation ID	Source Entity	Relationship	Target Entity
R001	Gene	ENCODES	Protein
R002	Gene	ASSOCIATED_WITH	Disease
R003	Gene	PARTICIPATES_IN	Pathway
R004	Protein	PARTICIPATES_IN	Pathway
R005	Protein	ASSOCIATED_WITH	Disease
R006	Protein	INTERACTS_WITH	Protein
R007	Drug	TARGETS	Protein
R008	Drug	TREATS	Disease
R009	Publication	SUPPORTS	Gene
R010	Publication	SUPPORTS	Protein
R011	Publication	SUPPORTS	Pathway
R012	Publication	SUPPORTS	Drug
R013	Publication	SUPPORTS	Disease

表 8: Phase 6.1 Relationship Schema Design

11.2 Phase 6.2: 关系提取

Phase 6.2 基于 Phase 5 生成的 Normalized Dataset 进行 Relationship Extraction。

主要输入数据包括：

- Gene Dataset；
- Protein Dataset；
- Pathway Dataset；
- Drug Dataset；
- Disease Dataset；
- Publication Dataset。

Relationship Extraction 主要依据以下信息：

- Database provided relationship information；
- Drug target annotation；
- Disease association information；
- Pathway membership information；
- Publication evidence。

经过 Relationship Extraction 后，首先获得：

447 条可以直接 Mapping 的 Relationship Instance

这些 Relationship 能够通过 Canonical Identifier 或者 Standard Name 直接匹配到 Phase 5 中的 Normalized Entity。

然而，在 Relationship Extraction 过程中仍然发现：

244 条无法直接 Mapping 的 Relationship

这些 Unresolved Relationship 主要来源于：

- Gene Symbol 不同；
- Protein Name 不一致；
- Alias 名称存在差异；
- 原始数据库使用非标准化名称；
- Entity 不属于当前 Knowledge Graph Scope。

因此，需要进一步进行 Relationship Mapping。

11.3 Phase 6.3：关系映射和验证

针对 244 条 Unresolved Relationship，本项目设计了四级 Mapping Strategy。

11.3.1 Level 1：精确匹配

首先检查 Relationship 中的 Source Entity 和 Target Entity 是否能够通过：

- Standard Name；
- Canonical Identifier；
- Database ID

进行直接匹配。

如果匹配成功，则 Relationship 进入 Validated Relationship Dataset。

11.3.2 Level 2: 规范标识符映射

对于无法 Exact Match 的 Entity, 进一步使用:

- Gene ID;
- UniProt ID;
- KEGG Pathway ID;
- DrugBank ID;
- Disease Ontology ID;
- PMID。

进行 Mapping。

由于这些 Identifier 具有唯一性, 因此可以有效避免名称歧义。

11.3.3 Level 3: 同义词及别名映射

如果 Canonical Identifier 不存在, 则进一步检查:

- Gene Synonyms;
- Protein Alternative Names;
- Drug Alias;
- Published Literature Naming。

只有经过验证的 Synonym Mapping 才会进入最终 Knowledge Graph。

11.3.4 Level 4: 排除未解决的关系

如果 Relationship 无法在当前 Entity Scope 中得到可靠 Mapping, 则不会进入 Knowledge Graph。

这些 Relationship 不会直接删除, 而是保留在 Mapping Audit 文件中, 用于:

- 后续数据扩展;
- Mapping 策略优化;
- 数据质量分析。

11.4 Phase 6.3 映射结果

经过上述 Mapping 流程：

Category	Number
Initial mapped relationships	447
Unresolved relationships	244
Successfully recovered relationships	22
Remaining unresolved relationships	222
Final validated relationships	469

表 9: Relationship Mapping Result

因此最终进入 Knowledge Graph 的 Relationship 数量为：

$$447 + 22 = 469$$

即：

469 条 Validated Relationships

222 条无法可靠 Mapping 的 Relationship 被排除，以保证 Knowledge Graph 中的数据质量。

11.5 Phase 6 最终输出

Phase 6 完成后生成最终 Neo4j Import Relationship Dataset：

MPM_Relationship_Final_Neo4j_469.xlsx

其中核心字段包括：

- Relationship ID
- Relation ID
- Source Entity
- Source Identifier
- Relationship Type
- Target Entity

- Target Identifier

Evidence 信息:

- Evidence Source
- Evidence Detail
- Mapping Status

保存在独立 Audit 文件中，不直接作为 Neo4j Relationship Property。

12 Phase 7: Neo4j 知识图谱构建

Phase 7 阶段负责将 Phase 5 中完成标准化处理的 Entity Dataset 以及 Phase 6 中完成验证的 469 条 Relationship Dataset 正式导入 Neo4j 图数据库，构建完整的 MPM 多组学生物医学知识图谱。

在 Phase 7 之前，项目已经完成：

- 六类标准化 Biomedical Entity Dataset；
- 469 条 Validated Relationships；
- 完整 Entity Schema；
- Relationship Schema。

因此，Phase 7 的核心目标是将已有的数据资源转换为真实的 Graph Database 结构。

12.1 Phase 7.1: Neo4j 环境配置

首先建立 Neo4j 运行环境，并创建用于 MPM Knowledge Graph 的数据库实例。

主要配置内容包括：

- Neo4j Database 安装与启动；
- Bolt Protocol 连接配置；
- 数据库用户权限配置；

- Python Neo4j Driver 环境配置。

本项目通过 Python Neo4j Driver 实现应用程序与 Neo4j 数据库之间的通信。

数据库连接模块负责：

- 创建数据库连接；
- 执行 Cypher Query；
- 返回查询结果；
- 管理数据库连接生命周期。

12.2 Phase 7.2: Node 构建

Phase 7.2 负责将 Phase 5 中的标准化 Entity 转换为 Neo4j 中的 Node。

最终知识图谱包含以下六类 Node：

- Gene；
- Protein；
- Pathway；
- Drug；
- Disease；
- Publication。

每一种 Entity 对应 Neo4j 中的一个 Label。

例如：

(:Gene)

(:Protein)

(:Pathway)

(:Drug)

(:Disease)

(:Publication)

每个 Node 保存 Phase 5 中对应 Entity 的标准化属性。

例如 Gene 节点包含：

- Gene ID;
- Standard Name;
- Description;
- Synonyms。

Protein 节点包含：

- UniProt ID;
- Protein Name;
- Function;
- Length。

12.3 Phase 7.3：规范化别名与约束设计

为了保证 Knowledge Graph 中 Entity 的唯一性, 本项目根据 Phase 5 定义的 Canonical Identifier (规范化别名) 建立 Neo4j Constraint (Neo4j 约束)。

对应关系如下：

Entity Type	Canonical Identifier	Neo4j Property
Gene	Gene ID	Gene _I D
Protein	UniProt ID	UniProt _I D
Pathway	Pathway ID	Pathway _I D
Drug	DrugBank ID	DrugBank _I D
Disease	DOID	DOID
Publication	PMID	PMID

表 10: Neo4j Entity Constraint 设计

通过 Unique Constraint, 可以避免同一 Entity 被重复导入。

例如:

```
CREATE CONSTRAINT gene_id_unique
FOR (g:Gene)
REQUIRE g.Gene_ID IS UNIQUE;
```

12.4 Phase 7.4: 关系数据导入

Phase 7.4 负责将 Phase 6 最终生成的 469 条 Validated Relationships 导入 Neo4j。Relationship 导入过程中:

- Source Entity 通过 Canonical Identifier 定位;
- Target Entity 通过 Canonical Identifier 定位;
- Relationship Type 保持 Phase 6 定义结果。

例如:

$$Gene \rightarrow ENCODES \rightarrow Protein$$

表示某 Gene 实体编码对应 Protein 实体。

其他 Relationship 包括:

$$Drug \rightarrow TARGETS \rightarrow Protein$$

以及:

$$Publication \rightarrow SUPPORTS \rightarrow Gene$$

最终 Neo4j 数据库中形成完整的 MPM Biomedical Knowledge Network。

12.5 Phase 7.5: 知识图谱系统验证

完成 Node 和 Relationship 导入后, 对知识图谱进行系统验证。

验证内容包括:

- Node 数量验证;

- Relationship 数量验证；
- Entity Label 验证；
- Relationship Type 验证；
- Source-Target 连接验证；
- Constraint 验证；
- Cypher Query 测试。

通过基础查询测试确认：

- Entity 可以正常检索；
- Relationship 可以正常返回；
- 多节点路径可以正常查询。

Phase 7 完成后，MPM Knowledge Graph 正式建立。

13 Phase 8: 知识图谱查询系统开发

Phase 8 负责开发基于 Neo4j Knowledge Graph 的查询系统，使研究人员能够通过用户界面对 MPM 相关 Biomedical Knowledge 进行检索、分析以及可视化。

系统采用三层架构：

Frontend Dashboard



FastAPI Backend Service



Neo4j Knowledge Graph Database

其中：

- Streamlit 负责用户交互和可视化；
- FastAPI 负责 API 接口服务；
- Neo4j 负责知识存储和图查询。

13.1 Phase 8.1: 数据库建立模块

Phase 8.1 首先建立 Python 与 Neo4j 之间的数据库连接模块。

主要功能包括：

- 创建 Neo4j Driver；
- 建立 Session；
- 执行 Cypher Query；
- 返回 Query Result。

该模块作为整个 Query System 的数据访问层。

13.2 Phase 8.2: 实体查找功能

Phase 8.2 实现基础 Entity Search。

用户可以输入：

- Gene 名称；
- Gene ID；
- UniProt ID；
- Pathway ID；
- DrugBank ID；
- DOID；
- PMID。

系统通过 Cypher Query 返回对应 Entity 信息。

例如：

输入：

TP53

系统返回：

- Entity Type;
- Standard Name;
- Gene ID;
- Related Identifier。

13.3 Phase 8.3: 关系搜索功能

Phase 8.3 实现单跳 Relationship 查询。

用户输入中心 Entity 后，系统返回：

- Source Entity;
- Relationship Type;
- Target Entity。

例如：

$BAP1 \rightarrow ASSOCIATED_WITH \rightarrow MPM$

查询结果进一步转换为 Graph JSON 格式，用于前端可视化。

13.4 Phase 8.4: 多条路径查询功能

Phase 8.4 实现知识图谱中的 multi-hop path query（多跳路径查询）功能。

相比 Phase 8.3 中的单跳 Relationship Exploration，Multi-hop Path Query 能够进一步探索两个 Biomedical Entity 之间的间接关联。

例如：

$$Gene \rightarrow Protein \rightarrow Pathway \rightarrow Disease$$

通过多跳路径查询，研究人员可以发现不同实体之间潜在的生物学关联。

13.4.1 查询功能设计

用户需要输入：

- Start Entity;
- End Entity。

系统将在 Neo4j Knowledge Graph 中搜索两个 Entity 之间的有效路径。

当前系统支持：

$$1 \sim 3$$

跳路径查询。

例如：

Start：

TP53

End：

DOID:7474

系统可能返回：

$$TP53 \rightarrow Protein \rightarrow Disease$$

或者：

$$TP53 \rightarrow Pathway \rightarrow Disease$$

13.4.2 路径结果格式

查询结果包括：

- Node Chain;
- Relationship Chain;
- Hop Length。

例如：

NodeChain:

TP53

-> Protein

-> Malignant Pleural Mesothelioma

RelChain:

ENCODES

-> ASSOCIATED_WITH

HopLength:

2

13.4.3 Graph Formatter

为了支持前端可视化，Phase 8.4 进一步开发 Graph Formatter 模块。
Formatter 负责将 Neo4j Query Result 转换为标准 Graph JSON 格式。
结构如下：

```
{  
  "nodes": [],
```



```
"edges": [],  
"summary": {}  
}
```

其中:

- nodes 保存图节点信息;
- edges 保存节点之间的 Relationship;
- summary 保存 Graph 统计信息。

该结构能够直接被 Streamlit Dashboard 中的 Graph Visualization 组件调用。

13.5 Phase 8.5: 文献查询功能

Phase 8.5 实现 Publication Evidence 查询功能。

在 Biomedical Knowledge Graph 中, Publication 作为 Evidence Layer, 用于支持 Gene、Protein、Pathway、Drug 以及 Disease 之间的 Relationship。

因此, 该模块用于回答:

“某个 Biomedical Entity 背后的文献证据是什么?”

13.5.1 查询对象

用户可以输入:

- Gene;
- Protein;
- Pathway;
- Drug;
- Disease。

系统通过 Publication 节点以及:

$$Publication \rightarrow SUPPORTS \rightarrow Entity$$

Relationship 进行查询。

13.5.2 返回信息

系统返回：

- PMID;
- Publication Title;
- Journal;
- Publication Year;
- Main Finding;
- Evidence Level;
- Supporting Entity。

例如：

对于 TP53 查询：

系统能够返回：

- TP53 相关研究；
- 文献发表时间；
- 研究发现；
- Evidence Level。

该功能增强了知识图谱的可解释性（Interpretability）。

相比单纯返回 Entity Relationship, Publication Evidence Query 能够提供 Biomedical Knowledge 背后的研究依据。

13.6 Phase 8.6: 药物-靶点-疾病闭环查询功能

Phase 8.6 实现 Drug-Target-Disease 闭环查询。

该模块用于分析：

$$Drug \rightarrow Target \rightarrow Gene \rightarrow Disease$$

之间的完整生物学关系。

13.6.1 查询目标

用户输入：

- Drug Name;
- DrugBank ID。

例如：

Pemetrexed

或者：

DB00642

系统返回该药物相关信息。

13.6.2 查询链路

主要查询路径包括：

$Drug \rightarrow TARGETS \rightarrow Protein$

以及：

$Protein \rightarrow ENCODES \rightarrow Gene$

同时结合：

$Drug \rightarrow TREATS \rightarrow Disease$

以及：

$Gene \rightarrow ASSOCIATED_WITH \rightarrow Disease$

形成完整 Drug-Target-Disease 闭环。

13.6.3 返回信息

系统返回：

- DrugBank ID;
- Drug Name;
- Mechanism;
- Clinical Status;
- Target Proteins;
- Related Genes;
- Related Disease。

该功能能够帮助研究人员快速分析：

某一药物通过哪些分子靶点影响 MPM 疾病机制。

13.7 Phase 8.7: Query Result Formatter

Phase 8.7 负责开发 Query Result Formatter 模块。

由于 Neo4j 返回的数据结构适合数据库查询，但不适合直接用于前端 Graph Visualization。

因此需要建立数据转换层。

13.7.1 Relationship Graph Formatter

该模块负责处理：

Entity – Relationship – Entity

类型查询结果。

输入：

Neo4j Relationship Query Result。

输出：

标准 Graph JSON。

格式：

```

{
  "nodes": [
    {
      "id": "",
      "label": "",
      "group": ""
    }
  ],

  "edges": [
    {
      "source": "",
      "target": "",
      "type": ""
    }
  ]
}

```

其中:

- Node group 用于区分 Entity Type;
- Edge type 表示 Relationship Type。

13.7.2 Multi-hop Graph Formatter

针对 Phase 8.4 产生的 Path Query Result, 系统进一步实现 Multi-hop Graph Formatter。

该模块负责:

- 提取 Node Chain;
- 提取 Relationship Chain;
- 构建完整 Graph Topology;
- 删除重复 Edge。

最终生成可供前端展示的知识图谱结构。

13.8 Phase 8.8: FastAPI 后端开发

Phase 8.8 负责开发后端 API 服务。

本项目采用 FastAPI 作为 Backend Framework。

后端主要职责包括：

- 接收 Frontend Request；
- 调用 Query Function；
- 执行 Neo4j Cypher Query；
- 返回 JSON Response。

系统主要 API 接口包括：

API Endpoint	Function	Phase
/api/entity/search	Entity Search	8.2
/api/relationship	Relationship Exploration	8.3
/api/path/multihop	Multi-hop Path Query	8.4
/api/publication	Publication Evidence Query	8.5
/api/drug-target	Drug Target Disease Query	8.6

表 11: FastAPI Backend API 设计


FastAPI Backend 使 Frontend Dashboard 与 Neo4j Database 实现解耦，提高系统可维护性。

13.9 Phase 8.9: Streamlit 交互式查询仪表盘开发

Phase 8.9 负责开发最终用户交互界面 (User Interface)，使研究人员能够通过可视化 Dashboard 访问 MPM Knowledge Graph。

本项目采用 Streamlit 作为 Frontend Framework。

Streamlit Dashboard 通过调用 Phase 8.8 开发的 FastAPI Backend API，实现：



的数据访问流程。

13.9.1 Dashboard 整体设计

系统 Dashboard 包含五个主要功能模块：

1. Entity Search;
2. Relationship Exploration;
3. Multi-hop Path Query;
4. Supporting Literature Evidence;
5. Drug-Target-Disease Chain。

用户可以根据研究需求选择不同 Query Module。

13.9.2 Module 1: Entity Search

Entity Search 模块提供基础实体检索功能。

用户可以输入：

- Gene 名称;
- Gene ID;
- Protein ID;
- Pathway ID;
- DrugBank ID;
- DOID;
- PMID。

系统调用：

/api/entity/search

API 接口返回对应 Entity 信息。

返回结果包括：

- Entity Type;
- Standard Name;
- Canonical Identifier;
- Related Information。

该模块用于快速定位 Knowledge Graph 中的目标 Entity。

13.9.3 Module 2: Relationship Exploration

Relationship Exploration 模块用于探索目标 Entity 的一跳邻居关系。

用户输入中心 Entity 后：

系统调用：

/api/relationship

返回：

- Source Entity;
- Relationship Type;
- Target Entity。

同时，系统将 Query Result 转换为 Graph JSON 结构。

通过 Streamlit Graph Visualization 组件展示：

Node + Edge

形式的知识网络。

不同 Entity Type 通过不同颜色进行区分：

- Gene;
- Protein;
- Drug;
- Disease;

- Pathway;
- Publication。

从而提高图谱可读性。

13.9.4 Module 3: Multi-hop Path Query

Multi-hop Path Query 模块用于探索两个 Entity 之间的潜在连接路径。

用户输入：

- Start Entity;
- End Entity。

系统调用：

/api/path/multihop

并返回：

- Path 数量;
- Node Chain;
- Relationship Chain;
- Hop Length。

查询结果进一步转换为 Graph Visualization。

研究人员可以通过可视化方式观察：

Entity → Relationship → Entity

之间的多跳关联。

13.9.5 Module 4: Supporting Literature Evidence

Supporting Literature Evidence 模块用于展示 Biomedical Evidence。

用户输入目标 Entity 后：

系统调用：

/api/publication

查询相关 Publication。

返回内容包括：

- PMID;
- Publication Title;
- Journal;
- Year;
- Main Finding;
- Evidence Level。

该模块保证 Knowledge Graph 中的 Biomedical Relationship 具有 Evidence Traceability。

13.9.6 Module 5: Drug-Target-Disease Chain

该模块用于展示 Drug 相关闭环关系。

用户输入：

- Drug Name;
- DrugBank ID。

系统调用：

/api/drug - target

返回：

- Drug Information;
- Target Protein;
- Related Gene;
- Associated Disease;
- Drug Mechanism。

该功能能够辅助研究人员分析：

$$Drug \rightarrow Target \rightarrow Disease$$

之间的潜在治疗机制。

14 Phase 9: AI 增强、系统测试与评估

Phase 9 作为项目后续扩展阶段，主要负责在已有 Knowledge Graph Query System 基础上进一步加入 AI 能力，并完成系统性能评估。

当前 Phase 9 主要规划三个方向：

1. AI Enhancement;
2. System Testing;
3. Performance Evaluation。

14.1 Phase 9.1: 知识图谱嵌入

Knowledge Graph Embedding (知识图谱嵌入) 旨在将 Graph 中的 Entity 和 Relationship 转换为低维向量表示。

通过 Embedding，可以进一步发现：

- 潜在 Gene-Protein 关系;
- 潜在 Drug-Target 关系;
- 未发现的 Disease 关联。

未来可以采用：

- Node2Vec;
- TransE;
- Graph Neural Network。

用于进一步挖掘 MPM 相关潜在生物机制。

14.2 Phase 9.2: 语义搜索

当前系统主要依赖：

- Entity Name;
- Identifier。

进行查询。

未来可以加入 Semantic Search（语义搜索），使用户能够通过自然语言描述查询 Knowledge Graph。

例如：

”Find genes associated with MPM progression”

系统可以自动转换为对应 Graph Query。

14.3 Phase 9.3: 大语言模型系统整合

未来系统可以结合 Large Language Model（LLM，大语言模型）实现 Knowledge Graph Enhanced Question Answering。

整体流程为：

$UserQuestion \rightarrow LLM \rightarrow KnowledgeGraphRetrieval \rightarrow Evidence - basedAnswer$

LLM 负责理解用户问题，Knowledge Graph 负责提供结构化 Biomedical Evidence。

14.4 Phase 9.4: 系统测试

在系统开发完成后，需要进行全面测试。

测试内容包括：

- Database Connection Test;
- API Endpoint Test;
- Query Function Test;
- Graph Visualization Test;
- Frontend Interaction Test。

目前系统已经完成：

- Entity Search 测试;
- Relationship Query 测试;
- Multi-hop Query 测试;
- Publication Query 测试;
- Drug-Target-Disease Query 测试。

所有核心功能均能够正常运行。

15 当前项目状态

截至当前版本，项目整体开发状态如下：

截至当前版本，本项目已经完成从 MPM 多组学生物医学数据收集、实体标准化、关系构建、知识图谱建立以及查询系统开发的完整流程。

项目最终实现了一个面向恶性胸膜间皮瘤（MPM）的多组学生物标志物知识图谱系统。

Project Phase	Status
Phase 1–3: Project Definition and Schema Design	Completed
Phase 4: Raw Dataset Construction	Completed
Phase 5: Entity Normalization and Data Cleaning	Completed
Phase 6: Relationship Construction	Completed
Phase 7: Neo4j Knowledge Graph Construction	Completed
Phase 8.1: Database Connection Module	Completed
Phase 8.2: Entity Search	Completed
Phase 8.3: Relationship Exploration	Completed
Phase 8.4: Multi-hop Path Query	Completed
Phase 8.5: Publication Evidence Query	Completed
Phase 8.6: Drug-Target-Disease Query	Completed
Phase 8.7: Query Result Formatter	Completed
Phase 8.8: FastAPI Backend Development	Completed
Phase 8.9: Streamlit Dashboard Development	Completed
Phase 9: AI Enhancement and Evaluation	Future Work

表 12: 项目当前开发状态

15.1 数据层成果

经过 Phase 4 至 Phase 6 的数据处理流程，本项目最终形成：

- 50 个 Gene 实体；
- 50 个 Protein 实体；
- 50 个 Pathway 实体；
- 20 个 Drug 实体；
- 1 个核心 Disease 实体（MPM, DOID:7474）；
- 100 个 Publication 实体；
- 469 条 Validated Relationships。

所有实体均经过 Entity Normalization 处理，并采用数据库中的 Canonical Identifier 作为唯一标识。

例如：

- Gene 使用 NCBI Gene ID;
- Protein 使用 UniProt ID;
- Pathway 使用 KEGG Pathway ID;
- Drug 使用 DrugBank ID;
- Disease 使用 Disease Ontology ID;
- Publication 使用 PMID。

15.2 知识图谱构建成果

通过 Neo4j 图数据库, 本项目成功将标准化后的 Entity Dataset 和 Relationship Dataset 转换为图结构数据。

知识图谱主要包含:

- Gene 节点;
- Protein 节点;
- Pathway 节点;
- Drug 节点;
- Disease 节点;
- Publication 节点;
- 多种生物学关系。

最终知识图谱能够表达:

Gene $\rightarrow$ Protein

Protein $\rightarrow$ Pathway

Drug $\rightarrow$ Protein

Drug $\rightarrow$ Disease

以及:

Publication $\rightarrow$ Biological Entity

等复杂医学知识关系。

15.3 查询系统成果

在 Phase 8 中，本项目完成了 MPM Knowledge Graph Query System 开发。
系统采用：

- Neo4j 作为图数据库；
- FastAPI 作为后端 API 服务；
- Streamlit 作为交互式 Dashboard。

系统目前支持以下查询功能：

功能模块	对应 Phase	描述
Entity Search	Phase 8.2	实体名称或 ID 查询
Relationship Exploration	Phase 8.3/8.7	单跳关系探索及图谱展示
Multi-hop Path Query	Phase 8.4/8.7	多跳路径发现
Publication Evidence Query	Phase 8.5	文献证据查询
Drug-Target-Disease Chain	Phase 8.6	药物闭环分析
Visualization Dashboard	Phase 8.9	交互式知识图谱展示

表 13: 查询系统功能总结

16 系统架构总结

本项目最终系统采用三层架构设计：

Frontend Layer ↓ Backend Service Layer ↓ Knowledge Graph Database Layer

16.1 Knowledge Graph Database Layer

底层采用 Neo4j 作为核心数据库。

主要负责：

- 存储 MPM 相关 Entity；
- 存储 Validated Relationships；
- 执行 Cypher 查询；
- 支持复杂路径搜索。

16.2 Backend Service Layer

后端采用 FastAPI 实现。

主要功能包括：

- 接收用户查询请求；
- 调用 Neo4j 数据库；
- 执行 Cypher Query；
- 返回标准 JSON 结果。


16.3 Frontend Layer

前端采用 Streamlit 实现交互式 Dashboard。

主要功能包括：

- 用户输入查询关键词；
- 展示实体信息；
- 展示关系网络；
- 展示多跳路径；
- 展示文献证据。

最终系统结构如下：



17 Phase 1–9 完整流程总结

本项目完整开发流程如下：

1. Phase 1: Project Definition

确定项目研究背景、MPM 疾病范围以及知识图谱建设目标。

2. Phase 2: Requirement Analysis

分析系统需求，确定数据需求、实体类型以及查询需求。

3. Phase 3: Schema Design

设计 Entity Schema 和 Relationship Schema，确定知识图谱整体结构。

4. Phase 4: Raw Dataset Construction

从 NCBI、UniProt、KEGG、DrugBank、Disease Ontology 以及 PubMed 收集原始数据。

5. Phase 5: Entity Normalization

对不同来源数据进行清洗、标准化以及 Canonical Identifier 统一。

6. Phase 6: Relationship Construction

完成 Relationship Schema 设计、Relationship Extraction 以及 Mapping Validation。

7. Phase 7: Neo4j Knowledge Graph Construction

将标准化 Entity 和 Validated Relationship 导入 Neo4j，建立 MPM 知识图谱。

8. Phase 8: Query System Development

开发 FastAPI Backend 和 Streamlit Dashboard，实现知识图谱查询与可视化。

9. Phase 9: AI Enhancement, Testing and Evaluation

进行系统测试、性能优化以及后续功能扩展。

18 未来扩展

目前系统已经完成基础知识图谱构建以及查询功能。

未来可以根据实际需求进行以下优化：

- 增加更多 MPM 相关 Gene、Protein 以及 Drug 数据；
- 增加更多 Publication 证据数据；
- 优化知识图谱可视化效果；
- 增加更加复杂的查询接口；
- 提升系统查询效率。

这些扩展将在保持当前系统架构稳定性的基础上进一步提高系统的完整性和实用性。

19 总结

本项目完成了一个面向恶性胸膜间皮瘤（MPM）的多组学生物标志物知识图谱构建与查询系统。

项目从数据收集开始，通过 Entity Normalization、Relationship Construction 以及 Neo4j Graph Database Construction，最终形成结构化医学知识网络。

同时，通过 FastAPI 和 Streamlit 开发交互式查询系统，使研究人员能够更加方便地访问 MPM 相关基因、蛋白质、通路、药物以及文献证据之间的关联关系。

本项目实现了从原始生物学数据到可查询知识图谱系统的完整开发流程，为后续 MPM 相关研究和数据分析提供了基础平台。